제10강: 시계열분석 2

금융 통계 및 시계열 분석

TRADE INFORMATIX

2014년 2월 11일

목차

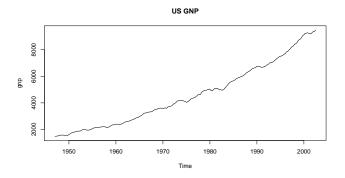
- 1 비정상 시계열 분석
 - 비정상 시계열
 - 정상상태 테스트
- 2 성분 모형
- 3 결정론적 추세 모형
- 4 결정론적 계절성 모형
- 5 확률적 추세 모형
- 6 확률적 계절성 모형
- 7 Transfer Function 모형

비정상 시계열 (Non-stationary Time Series)

- □ 비정상 시계열 (Non-stationary Time Series)
 - ▶ 시간에 따라 평균 (mean), 공분산 (covariance) 등이 변화
- □ 비정상 시계열의 예
 - ▶ GDP, CPI 등 경제성장과 함께 증가하는 수치
 - ▶ 누적 거래량 등 시간에 따라 누적된 수치
 - ▶ 자연현상, 에너지 사용량 등 강한 계절성을 가지는 수치
 - ▶ 변동성의 크기가 변화하는 수치
- □ 모형 방법론
 - ▶ 성분(Component) 모형
 - ▶ 분산변동 (Heteroskedastic) 모형

비정상 시계열의 예: 추세

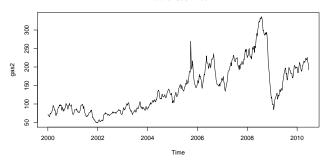
```
> require(astsa, quietly=TRUE)
> data(gnp)
> plot(gnp, main="US GNP")
```



비정상 시계열의 예: 계절성

```
> require(astsa, quietly=TRUE)
> data(gas)
> N <- length(gas)
> gas2 <- window(gas, start=1975)
> plot(gas2, type='l', main="Natural Gas Price")
```

Natural Gas Price



정상상태 테스트 (Stationary Test)

- □ 시계열이 정상상태 조건을 만족하는지 검사
- ☐ Unit Root Test
- □ 종류
 - ► ADF(Augmented Dickey-Fuller) Test
 - ► PP(Phillps-Peron) Test
 - ► ERS(Elliot-Rothenberg-Stock) Test
 - ► SP(Schmidt-Phillips) Test
 - ► KPSS(Kwiatkowski-Phillips-Schmidt-Shin) Test

(Augmented) Dickey-Fuller Test

- Original DF Test
 - ▶ AR(1) 시계열의 계수 a₁ 이 1인지 테스트
 - ightharpoonup 실제로는 Δx_t 와 x_{t-1} 의 회귀분석 계수가 0인지 테스트

$$\begin{array}{rcl} x_t & = & a_1 x_{t-1} + w_t \\ \\ x_t - x_{t-1} & = & a_1 x_{t-1} - x_{t-1} + w_t \\ \\ \Delta x_t & = & (1 - a_1) x_{t-1} + w_t \end{array}$$

- ▶ residual의 autocorrelation 문제
- Augmented DF Test
 - ▶ AR(p) 시계열 모형 이용

$$\Delta x_t = (1 - a_1)x_{t-1} + \sum_{j=1}^p c_j \Delta x_j + w_t$$

R에서 ADF 테스트 사용

- □ 다양한 패키지에서 구현
 - ▶ fUnitRoots 패키지의 adftest
 - ▶ tseries 패키지의 adf.test
 - ▶ urca 패키지의 ur.df
 - ▶ uroot 패키지의 ADF.test
- ☐ ur.df(x, type, lags=1, selectlags)
 - ▶ x): 시계열 자료
 - ▶ type) : 추세성분을 추가하는 경우 "trend"
 - ▶ lags: residual autocorrelation 모형차수

```
> require(urca, quietly=TRUE)

> data(Raotbl3)

> attach(Raotbl3)

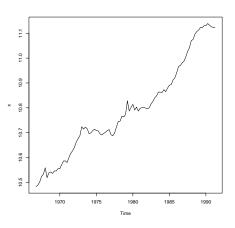
> x <- ts(lc,

+ start=c(1966,4),

+ end=c(1991,2),

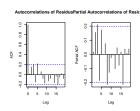
+ frequency=4)

> plot(x)
```

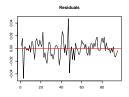


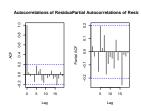
```
> m <- ur.df(x, lags=1)
> plot(m)
> summarv(m)
# Augmented Dickey-Fuller Test Unit Root Test #
Test regression none
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
Residuals:
     Min
               1Q Median
-0.043588 -0.007067 0.000962 0.007999 0.048462
Coefficients:
            Estimate Std Error t value Pr(>|t|)
z.lag.1
           0.0006805 0.0001433 4.749 7.24e-06 ***
z.diff.lag -0.1243891 0.1020458 -1.219
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.0137 on 95 degrees of freedom
Multiple R-squared: 0.198, Adjusted R-squared: 0.1811
F-statistic: 11.73 on 2 and 95 DF, p-value: 2.812e-05
Value of test-statistic is: 4.7485
Critical values for test statistics:
    1pct 5pct 10pct
tau1 -2.6 -1.95 -1.61
```



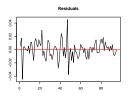


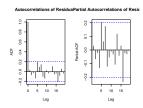
```
> m <- ur.df(x, lags=3)
> plot(m)
> summary(m)
# Augmented Dickey-Fuller Test Unit Root Test #
Test regression none
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
Residuals:
     Min
              10
                    Median
-0.047220 -0.007276 0.000229 0.007674 0.046921
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
           0.0004083 0.0001695
                              2.409
z.lag.1
                                    0.0180 *
z.diff.lag1 -0.1444994 0.1007615 -1.434
                                      0.1550
z.diff.lag2 0.1599782 0.1009153
                              1.585
                                      0 1164
z.diff.lag3 0.2568572 0.1015353
                              2.530
                                      0.0131 *
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
Residual standard error: 0.0133 on 91 degrees of freedom
Multiple R-squared: 0.2546, Adjusted R-squared: 0.2218
F-statistic: 7.77 on 4 and 91 DF, p-value: 1.967e-05
Value of test-statistic is: 2,4089
Critical values for test statistics:
    1pct 5pct 10pct
tau1 -2.6 -1.95 -1.61
```





```
> m <- ur.df(x, lags=3, type="trend")
> plot(m)
> summarv(m)
# Augmented Dickey-Fuller Test Unit Root Test #
Test regression trend
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
Residuals:
     Min
                    Median
-0.044714 -0.006525 0.000129 0.006225 0.045353
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.7976591 0.3547775
                              2.248
                                      0.0270 *
          -0.0758706 0.0338880 -2.239 0.0277 *
z.lag.1
                              2.277
                                      0.0252 *
           0.0004915 0.0002159
z.diff.lag1 -0.1063957 0.1006744 -1.057
                                       0.2934
z.diff.lag2 0.2011373 0.1012373
                              1.987
                                       0.0500 .
z.diff.lag3 0.2998586 0.1020548
                              2.938
                                       0 0042 **
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
Residual standard error: 0.01307 on 89 degrees of freedom
Multiple R-squared: 0.1472, Adjusted R-squared: 0.09924
F-statistic: 3.071 on 5 and 89 DF. p-value: 0.01325
Value of test-statistic is: -2.2389 3.7382 2.5972
Critical values for test statistics:
     1pct 5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2 6.50 4.88 4.16
phi3 8.73 6.49 5.47
```





Pillips-Perron Test

□ Non-parametric test로 AR차수지정이 필요하지 않음

$$\Delta x_t = \mu + \alpha x_{t-1} + w_t$$

- □ 데이터 수가 적을 경우 정확성이 떨어짐
 - ▶ tseries 패키지의 pp.test
 - ▶ urca 패키지의 ur.pp
- ☐ ur.pp(x, model)
 - ▶ x): 시계열 자료
 - ▶ model) : 추세성분을 추가하는 경우 "trend"

```
> m <- ur.pp(x)
> summary(m)
# Phillips-Perron Unit Root Test #
*******************************
Test regression with intercept
Call:
lm(formula = y ~ y.11)
Residuals:
     Min
                10 Median
                                   30
                                            Max
-0.047503 -0.007042 0.001483 0.007879 0.047975
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.010867 0.082462 0.132 0.895
           0.999597 0.007643 130.779 <2e-16 ***
v.11
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.01374 on 96 degrees of freedom
Multiple R-squared: 0.9944, Adjusted R-squared: 0.9944
F-statistic: 1.71e+04 on 1 and 96 DF. p-value: < 2.2e-16
Value of test-statistic, type: Z-alpha is: -0.0572
        any 7 statistics
Z-tau-mu
                   0.1509
```

성분 모형 (Component Model)

- □ 다양한 비정상 특성을 보이는 시계열을 특성별로 나누어 모형화하는 방법
 - ▶ 추세 (trend)
 - 결정론적 (deterministric) 추세
 - 확률적 (stochastic) 추세
 - ▶ 계절성 (seasonality)
 - 결정론적 계절성
 - 확률적 계절성
 - ▶ 확률론적 정상 신호
 - ARMA
- □ 추세 조합 방법
 - ▶ Additive Model
 - ► Multiplicative Model

결정론적 추세 모형

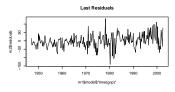
- □ 회귀분석을 이용, 추세 성분을 표시하는 결정론적 함수을 추정
- □ 보통 1차 (linear) 혹은 2차 (quadratic) 회귀분석 사용
- □ 비선형성을 보정하기 위한 log 변환(transformation) 등을 사용할 수 있음

결정론적 추세 모형의 예 1: 선형 추세 + ARMA

```
> require(forecast, quietly=TRUE)
> (m1 <- lm(gnp~time(gnp)))
Call:
lm(formula = gnp ~ time(gnp))
Coefficients:
(Intercept)
              time(gnp)
  -272289.7
                   140 2
> (m2 <- arima(m1$residuals, order=c(1, 0, 1)))
Series: m1$residuals
ARIMA(1.0.1) with non-zero mean
Coefficients:
        ar1
                ma1 intercept
      0 9960 0 2779
                       613 1519
s.e. 0.0038 0.0534
                       497,7602
sigma^2 estimated as 1591: log likelihood=-1141.13
ATC=2290.26
             ATCc=2290.44
                             BTC=2303.89
> lavout(matrix(1:3))
> plot(gnp, main="US GNP and Linear Trend")
> lines(m1$model$"time(gnp)", m1$fitted.values,
        col="red")
> plot(m1$model$"time(gnp)", fitted(m2),
       type='l', main="Trend Residuals")
> lines(m1$model$"time(gnp)", fitted(m2),
        col="red")
 plot(m1$model$"time(gnp)", m2$residuals,
       type='l', main="Last Residuals")
```





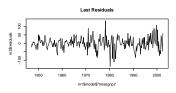


결정론적 추세 모형의 예 2: 2차 추세 + ARMA

```
> require(forecast, quietly=TRUE)
> (m1 <- lm(gnp~time(gnp)+I(time(gnp)^2)))
Call:
lm(formula = gnp ~ time(gnp) + I(time(gnp)^2))
Coefficients:
   (Intercept)
                    time(gnp) I(time(gnp)^2)
    6.462e+06
                    -6 681e+03
                                     1 727e+00
> (m2 <- arima(m1$residuals, order=c(1, 0, 1)))
Series: m1$residuals
ARIMA(1.0.1) with non-zero mean
Coefficients:
        ar1
                 ma1 intercept
      0 9420 0 2499
                         4 8782
s.e. 0.0221 0.0560
                        50 8461
sigma^2 estimated as 1422: log likelihood=-1127.26
ATC=2262.51
             ATCc=2262.69
                             BTC=2276.14
> lavout(matrix(1:3))
> plot(gnp, main="US GNP and Linear Trend")
> lines(m1$model$"time(gnp)", m1$fitted.values,
        col="red")
 plot(m1$model$"time(gnp)", fitted(m2),
       type='l', main="Trend Residuals")
> lines(m1$model$"time(gnp)", fitted(m2),
        col="red")
 plot(m1$model$"time(gnp)", m2$residuals,
       type='l', main="Last Residuals")
```

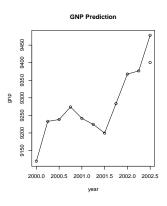






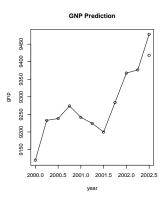
선형 추세 + ARMA 모형을 이용한 예측

```
> N <- length(gnp); v <- gnp[-N]; x <- time(gnp)[-N];
> m1 <- lm(v~x)
> m2 <- arima(m1$residuals, order=c(1, 0, 1))
> new <- data.frame(x=time(gnp)[N])
> (p1 <- predict(m1, new))
8444.629
> (p2 <- predict(m2, n.ahead=1))
$pred
Time Series:
Start = 223
End = 223
Frequency = 1
[1] 955.8833
Time Series:
Start = 223
End = 223
Frequency = 1
[1] 39.65396
> (p <- p1 + p2$pred)
Time Series:
Start = 223
End = 223
Frequency = 1
9400.512
> gnp[N]
Γ17 9477.9
> plot(window(gnp, start=2000),
       type='o',
       xlab="year", ylab="gnp",
       main="GNP Prediction")
> points(time(gnp)[N], p)
```



2차 추세 + ARMA 모형을 이용한 예측

```
> N <- length(gnp); v <- gnp[-N]; x <- time(gnp)[-N];
> m1 <- lm(v~x+I(x^2))
> m2 <- arima(m1$residuals, order=c(1, 0, 1))
> new <- data.frame(x=time(gnp)[N])
> (p1 <- predict(m1, new))
9340.238
> (p2 <- predict(m2, n.ahead=1))
$pred
Time Series:
Start = 223
End = 223
Frequency = 1
[1] 77.76912
Time Series:
Start = 223
End = 223
Frequency = 1
[1] 37.59129
> (p <- p1 + p2$pred)
Time Series:
Start = 223
End = 223
Frequency = 1
9418,007
> gnp[N]
Γ17 9477.9
> plot(window(gnp, start=2000),
       type='o',
       xlab="year", ylab="gnp",
       main="GNP Prediction")
> points(time(gnp)[N], p)
```



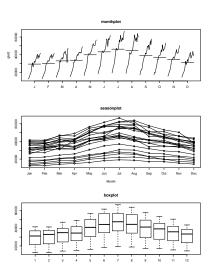
결정론적 계절성 모형

- □ 사이클 모형 (Cycle Model)
 - ▶ 단일 주기를 가지는 경우
- □ 주파수 모형 (Harmonics Model)
 - ▶ 복수의 sin/cos 주기신호의 조합으로 표시

R 사이클 모형 명령 1

- □ monthplot (forecast 패키지) : 연단위 평균과 월 패턴을 같이 플롯
- □ seasonplot (forecast 패키지) : 월 간격으로 플롯

```
> require(astsa, quietly=TRUE)
> data(gas)
> N <- length(gas)
> gas2 <- window(gas, start=1975)
> layout(matrix(1:3))
> monthplot(gas2,
+ main="monthplot")
> seasomplot(gas2,
+ main="seasonplot")
> boxplot(gas2-cycle(gas2),
+ main="boxplot")
```



R 사이클 모형 명령 2

□ cycle: 1년 주기의 시계열의 월 팩터 시계열 생성

□ aggregate : 연간 총합 시계열 생성

```
> cvcle(gas2)
    Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
1975
1976
1977
1978
1979
1980
                                       10
1981
                                       10
                                           11
1982
1983
                                           11
1984
                                           11
1985
                                       10
                                           11 12
1986
1987
                                           11 12
1988
1989
                                           11 12
1990
                                 8 9 10
1991
                                           11 12
1992
                          6 7 8 9 10
                                           11 12
1993
                        6 7 8 9 10 11 12
1994
                                     9 10 11 12
1995
> aggregate(gas2)
Time Series:
Start = 1975
End = 1994
Frequency = 1
 [1] 190428 220645 245077 269459 291470 345982 418393 432898
 [9] 438038 455014 461061 474263 517757 535174 580150 560521
[17] 537544 571926 555988 612430
```

R 사이클 모형 추정

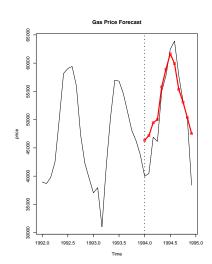
- □ 1m 명령 사용
- □ 설명계수: 0, time, factor(cycle)

```
> (m <- lm(gas2 ~ 0 + time(gas2) + factor(cycle(gas2))))
Call:
lm(formula = gas2 ~ 0 + time(gas2) + factor(cycle(gas2)))
Coefficients:
           time(gas2)
                        factor(cycle(gas2))1
                 1764
                                     -3473201
 factor(cvcle(gas2))2
                        factor(cycle(gas2))3
             -3472429
                                     -3469859
 factor(cycle(gas2))4
                        factor(cycle(gas2))5
             -3469261
                                     -3463255
 factor(cycle(gas2))6
                        factor(cycle(gas2))7
             -3460049
                                     -3457147
 factor(cycle(gas2))8
                        factor(cycle(gas2))9
             -3458960
                                     -3463517
factor(cycle(gas2))10
                       factor(cycle(gas2))11
             -3465871
                                     -3468614
factor(cycle(gas2))12
             -3471909
```

R 사이클 모형 예측

- □ 1m 명령 사용
- □ 설명계수 0, time factor(cycle)

```
gas3 <- window(gas2, end=c(1993,12))
> t <- time(gas3)
 c <- factor(cycle(gas3))
> m <- lm(gas3 ~ 0 + t + c)
> new <- data.frame(t=rep(1994, 12),
                    c=factor(1:12))
  p <- ts(predict(m, new),
          start=c(1994.1).
          freq=12)
 plot(window(gas2, type='o',
              start=c(1992,1),
              end=c(1994,12)),
      main="Gas Price Forecast".
      vlab="price")
> lines(p, col="red", lwd=4)
> points(p, col="red", pch=0)
> abline(v=1994, lwd=3, lty="dotted")
```



확률적 추세 모형: Integrated 모형, ARIMA 모형

- □ order-d Integrated 모형, I(d)
 - ▶ d 번 차분 (difference) 하면 정상 (stationary) 상태가 되는 시계열
 - ▶ 차분 정상 (difference-stationary) 모형
 - ▶ 정상시계열은 0차 integrated 모형, I(0)
- ☐ Unit Root 프로세스, I(1)
 - ▶ 1차 Integrated 모형
 - $\Delta x_t = x_{t+1} x_t$ 가 정상
- □ ARIMA(p,d,q) 모형 (Auto-Regressive Integrated Moving Average)
 - ▶ d 번 차분 (difference) 하면 ARMA(p,q) 모형이되는 시계열
 - \blacktriangleright 특성방정식의 해 중 d개가 1, 나머지는 절대값이 1보다 큼

$$\theta_p(B)(1-B)^d x_t = \phi_q(B) w_t \tag{1}$$

랜덤워크 (Random Walk)

- □ 랜덤워크
 - ► ARIMA(0,1,0) 모형

$$x_t - x_{t-1} = w_t$$
 or, $x_t = x_{t-1} + w_t$ (2)

여기에서 $w_t \sim N(0, \sigma)$

▶ 평균은 0이지만 분산은 시간에 따라 증가

$$E[x_t] = 0 (3)$$

$$Var[x_t] = \sigma^2 t \tag{4}$$

- ▶ unit root process의 특별한 경우
- □ drift가 있는 랜덤워크

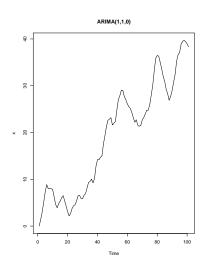
$$x_t = x_{t-1} + \mu + w_t = x_0 + \mu t + \sum_{i=0}^{t} w_i$$
 (5)

- ▶ 결정론적 추세가 있는 랜덤워크
- ▶ 단기/일중 주가 모형

ARIMA 모형의 시뮬레이션

- ☐ arima.sim(model, n)
 - ▶ model=list(order, ar, ma) : 차수 및 계수 벡터
 - ▶ n: 시뮬레이션 갯수

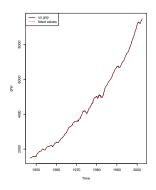
```
> set.seed(1)
> m <- list(order = c(1,1,0), ar = 0.7)
> x <- arima.sim(m, 100)
> plot(x, main="ARTMA(1,1,0)")
```



ARIMA 모형의 추정

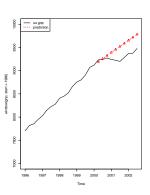
- ☐ arima(x, order)
 - ▶ x: 시계열 자료
 - ▶ order=c(p,d,q):차수
- □ auto.arima(x): forecast 패키지
 - ▶ x: 시계열 자료

```
> m <- auto.arima(gnp)
> summary(m)
Series: gnp
ARIMA(2,2,1)
Coefficients:
                 ar2
      0 2799 0 1592 -0 9735
s.e. 0.0682 0.0682
                      0.0142
sigma^2 estimated as 1451: log likelihood=-1119.01
AIC=2246.02
             AICc=2246.21
                           BIC=2259.62
Training set error measures:
                          RMSE
                                    MAE
                                               MPE
Training set 3.735674 37.91694 29.15062 0.08532321
                  MAPE
                            MASE
Training set 0.7254322 0.1855389 -0.009664696
> plot(gnp)
> lines(fitted(m), col="red", lwd=2, lty=2)
> legend("topleft", col=c("black", "red"),
         ltv=1:2.
         c("us gnp", "fitted values"))
```



ARIMA 모형을 이용한 예측

```
> m <- auto.arima(window(gnp, end=2000))
> p <- predict(m, n.ahead=10)
> plot(window(gnp, start=1996),
+ ylim=(7000, 10000))
> lines(p$pred, col="red", lwd=2, lty=2)
> points(p$pred, col="red", pch=2)
> legend("topleft", col=c("black", "red"),
+ lty=1:2,
+ c("us gnp", "prediction"))
```



확률적 계절성 모형: SARIMA 모형

☐ Seasonal ARIMA 모형: ARIMA(p,d,q)(P,D,Q)[S]

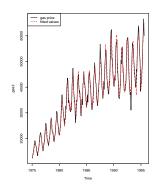
$$\theta_P(B^s)\theta_P(B)(1-B^s)^D(1-B)^d x_t = \phi_Q(B^s)\phi_Q(B)w_t$$
 (6)

- ▶ ARIMA(p,d,q) 모형에 주기 s의 ARIMA(P,D,Q) 모형을 결합
- □ 주기 s의 ARIMA(P,D,Q) 모형
 - ▶ s의 배수만큼 과거의 신호만을 이용한 모형
 - $\blacktriangleright x_t \vdash x_{t-s}, x_{t-s2}, \cdots, w_t, w_{t-s}$ 등에만 영향을 받음

SARIMA 모형의 추정

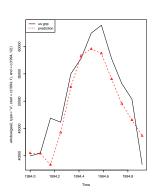
- ☐ arima(x, order, seasonal)
 - ▶ seasonal=list(order=c(P,D,Q),period)): 계절성 차수
- ☐ auto.arima(x, d, D, max.p, max.q, max.P, max.Q, seasonal)
 - ▶ d, D: integration 차수
 - ▶ max.p, max.q, max.P, max.Q: 최대 가능 ARMA 차수
 - ▶ seasonal : TRUE이면 계절성 추가

```
> m <- auto.arima(gas2)
> summarv(m)
Series: gas2
ARIMA(2,1,1)(2,0,0)[12]
Coefficients:
                ar2
     0.4815 0.2072 -0.9606 0.5481
s.e. 0.0733 0.0724
                      0.0297 0.0619 0.0629
sigma^2 estimated as 5308472: log likelihood=-2271.23
ATC=4554 47 ATCc=4554 82 BTC=4575 52
Training set error measures:
                                   MAE
Training set 178.4515 2299.362 1641.488 0.4011571 4.404438
Training set 0.5566454 -0.005337921
> plot(gas2)
> lines(fitted(m), col="red", lwd=2, lty=2)
> legend("topleft", col=c("black", "red"),
        ltv=1:2.
        c("gas price", "fitted values"))
```



SARIMA 모형을 이용한 예측

```
> m <- auto.arima(window(gas2, end=c(1993,12)))
> p <- predict(m, n.ahead=12)
> plot(window(gas2, type='o',
+ start=c(1994,1), end=c(1994,12)))
> lines(p$pred, col="red", lwd=2, lty=2)
> points(p$pred, col="red", pch=2)
> legend("topleft", col=c("black", "red"),
+ lty=1:2,
+ c("us gnp", "prediction"))
```



Transfer Function 모형

- ☐ ARMAX 모형
- □ ARMA 모형과 형식은 같으나 random innovation이 아닌 기지의 (known) 외부 입력 시계열을 가진다.

$$\theta_p(B)x_t = \phi_q(B)x_t + \psi_r(B)w_t \tag{7}$$

- \square $\theta_p(B)^{-1}\phi_q(B)$ 는 외부입력에 대한 Impulse Response Function
- □ TSA 패키지의 arima 혹은 arimax 명령을 사용
- ☐ arimax(x, order, xreg)
 - ▶ xreg : 외부 입력 시계열