

## 제16강: HMM(Hidden Markov Model)

금융 통계 및 시계열 분석

TRADE INFORMATIX

2014년 3월 4일

- 1 혼합 모형 (Mixuture Model)
  - 독립적 혼합 모형 (Independent Mixuture Model)
  
- 2 히든 마코프 모형 (Hidden Markov Model)
  - 마코프 체인 (Markov Chain)
  - 히든 마코프 모형 (Hidden Markov Model)
  
- 3 히든 마코프 모형의 추정
  - HMM 파라미터 추정 문제
  - HMM Likelihood
  - HMM MLE의 어려움
  - EM Algorithm
  - Decoding
  - 실제 주가에 HMM 응용

# 독립적 혼합 모형 (Independent Mixuture Model)

- 복수의 연속확률분포 중 하나를 확률적으로 선택하는 조합 방법
- 분포 선택은 독립적인 이산 확률분포를 사용

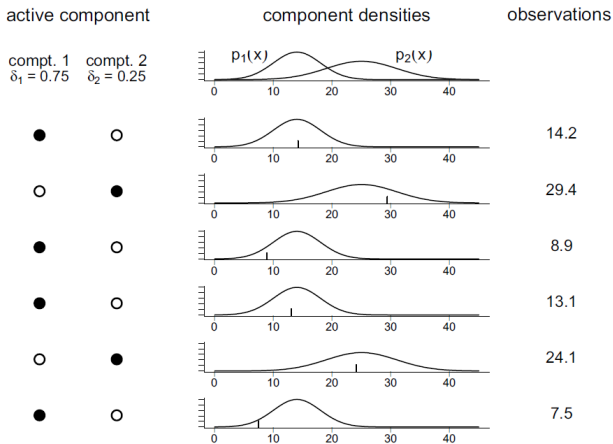
$$p(x) = \Pr(X = x) = \sum_{i=1}^m \Pr(C = i) \cdot \Pr(X = x|C = i) = \sum_{i=1}^m \delta_i p_i(x)$$

- ▶  $p(x)$  : 전체 Independent Mixuture 분포
- ▶  $p_i(x)$  : Independent Mixuture의 각 성분(component)이 되는 개별적인 연속 확률분포
- ▶  $\delta_i$  : mixing parameter. 특정시간에 대해 모든 성분 중 특정한  $p_i(x)$ 가 선택될 확률
- ▶  $\sum \delta_i = 1$  : mixing parameter에 대한 확률 제한 조건

# 독립적 혼합 모형의 예

## □ Binomial Normal-Mixutture 모형

- ▶ 각 성분은 Normal 연속 분포이고
- ▶ 성분을 선택하는 이산분포는 Binomial 분포



# Mixture 모형의 파라미터 추정

- ❑ Maximum Likelihood Estimation 사용
- ❑  $n$  개의 샘플에 대한 Mixture 모형의 Likelihood 함수

$$L(\theta_1, \dots, \theta_m, \delta_1, \dots, \delta_m | x_1, \dots, x_n) = \prod_{j=1}^n \sum_{i=1}^m \delta_i p_i(x_j, \theta)$$

- ❑ 덧셈과 곱셈이 혼합되어 있는 복잡한 함수
- ❑ 일반적인 Log-Differentiation 방법 사용 불가
- ❑ mixing parameter 제한 조건 준수
- ❑ Constrained Non-linear Optimization 또는 EM 알고리즘 사용
- ❑ Zero-Variance Spike 문제

# 마코프 체인 (Markov Chain)

- 다음과 같은 마코프 (Markov) 특성을 가지는 이산시간 확률 프로세스

$$\Pr(C_{t+1}|C_t, \dots, C_1) = \Pr(C_{t+1}|C_t)$$

- 전이확률 (Transition Probability)

- ▶ 특정 시간  $t$  동안 특정한 한 상태  $i$ 에서 특정한 다른 상태  $j$ 로 전이할 확률

$$\gamma_{ij}(t) = \Pr(C_{s+t} = j | C_s = i)$$

- 전이확률행렬 (Transition Probability Matrix)

$$\Gamma(t) = \{\gamma_{ij}(t)\} \quad \Gamma = \Gamma(1)$$

- Chapman-Kolmogorov Equation

- ▶ 시간  $t + u$ 의 전이확률행렬은 시간  $t$ 의 전이확률행렬과 시간  $u$ 의 전이확률행렬의 곱

$$\Gamma(t + u) = \Gamma(t)\Gamma(u)$$

## □ Unconditional Probability

- ▶  $t$ 라는 시점에 특정한 이산 상태에 있을 확률, 즉 특정한 component가 선택될 확률

$$u(t) = (\Pr(C_t = 1), \Pr(C_t = 2), \dots, \Pr(C_t = m))$$

$$u(t+1) = u(t)\Gamma$$

## □ Stationary Distribution

- ▶ 시간이 지나도 unconditional probability가 변하지 않는 경우

$$\delta = \delta\Gamma$$

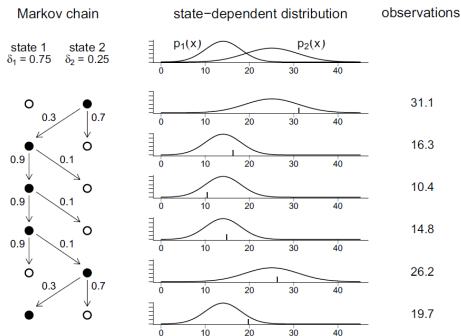
# 히든 마코프 모델 (Hidden Markov Model)

## Hidden Markov Model

- ▶ 연속 확률 분포를 선택하는 파라미터 프로세스 (Parameter Process) 가 마코프 체인 (Markov Chain) 이고 연속확률분포가 그 시점의 파라미터 프로세스의 샘플값에만 의존하는 Mixture Model
- ▶ 연속확률분포의 샘플값만 측정가능

$$\Pr(C_t | C_{t-1}, \dots, C_1) = \Pr(C_t | C_{t-1})$$

$$\Pr(X_t | X_t, \dots, X_1, C_t, \dots, C_1) = \Pr(X_t | C_t)$$






# 히든 마코프 모형 시뮬레이션

- ❑ RHmm 패키지 사용
- ❑ `distributionSet` 명령으로 연속분포 집합 생성
- ❑ `HMMSet` 명령으로 HMM 오브젝트 생성
- ❑ `HMMSim` 명령으로 시뮬레이션
- ❑ `distributionSet(dis="NORMAL", mean, variance)`
  - ▶ `dis`: 연속분포 모형 'NORMAL', 'DISCRETE', 'MIXTURE'
  - ▶ `mean, variance`: `dis='NORMAL'`인 경우 파라미터
- ❑ `HMMSet(initProb, transMat, distribution)`
  - ▶ `initProb`: 초기 이산확률분포
  - ▶ `transMat`: 확률전이행렬 (Probability Transition Matrix)
  - ▶ `distribution`: `distributionSet` 명령으로 생성한 연속분포 집합
- ❑ `HMMSim(nSim, HMM)`
  - ▶ `nSim`: 시뮬레이션 횟수
  - ▶ `HMM`: `HMMSet` 명령으로 생성한 HMM 오브젝트


# 히든 마코프 모형 시뮬레이션 예

```
> library("RHmm")
> set.seed(2)
> n_1d_3s <- distributionSet("NORMAL", mean=c(1, 0.05, -2), var=c(1, 2, 4))
> initProb3 <- rep(1,3)/3
> transMat3 <- rbind(c(0.9, 0.09, 0.01), c(0.05, 0.9, 0.05), c(0.05, 0.1, 0.85))
> hmm_1d_3s <- HMMSet(initProb3, transMat3, n_1d_3s)
> simul <- HMMSim(2500, hmm_1d_3s)
> hist(simul$obs, breaks=50)
```



# 히든 마코프 모형 시뮬레이션 예

```
> par(mfrow=c(3,1))  
> plot(simul$obs, type='l', main="HMM Simulation", ylab="Return Observations")  
> plot(simul$states, type='l', ylab="Discrete States")  
> plot(100*exp(cumsum(simul$obs/100.0)), type='l', ylab="Price Observations")
```



# HMM 파라미터 추정 문제

- 관측된  $n$  개의 확률변수 샘플  $\{X_i\}, (i = 1, \dots, n)$ 로부터 component 연속확률분포의 파라미터와 Mixing Parameter Process인 Markov Chain의 파라미터를 동시에 추정하는 문제
- Mixing Parameter Process는 Probability Transition Matrix의 형태로 추정
- Probability Transition Matrix는  $m^2$ 의 파라미터를 가지지만 실제로는 각 행의 합이 1 이므로  $m(m - 1)$ 의 파라미터가 된다.

$$L(\theta_1, \dots, \theta_m, \gamma_{11}, \dots, \gamma_{mm} | x_1, \dots, x_n)$$

- Maximum Likelihood Estimation 방법론 이용
- 다양한 제한조건이 존재
- EM Method (Baum-Welch Method) 사용

- 샘플  $\{x_1, x_2, \dots, x_T\}$ 가 주어졌을 때 이 샘플에 대한 Likelihood 함수  $L_T$ 는 다음과 같이 주어진다.

$$\begin{aligned} L_T &= u(1)P(x_1)\Gamma P(x_2)\Gamma P(x_3)\cdots\Gamma P(x_T)1^T \\ &= u(1)P(x_1)\prod_{s=2}^m \Gamma P(x_s)1^T \end{aligned}$$

- ▶  $u(1)$  :  $t = 1$ 에서의 component 선택 확률

$$u(1) = (\Pr(C_1 = 1), \Pr(C_1 = 2), \dots, \Pr(C_1 = m))$$

- ▶  $P(x)$  : 각각의 component분포가  $x$ 이 될 확률을 대각성분으로 가지는 대각행렬

$$P(x) = \text{diag}(p_1(x), p_2(x), \dots, p_m(x))$$

# HMM MLE의 어려움

## □ 제한 조건 문제

- ▶ Probability Transition Matrix의 모든 원소는 0과 같거나 크다

$$\gamma_{ij} \geq 0 \text{ for all } i, j$$

- ▶ Probability Transition Matrix의 각 행의 값의 합은 1

$$\sum_{i=1}^m \gamma_{ij} = 1$$

- ▶ 제한 조건 문제를 풀기 위해 다음과 같은 변환 사용

$$\begin{aligned}\gamma_{ij} &= \frac{\rho_{ij}}{\sum_{k=1}^m \rho_{ik}} \\ \rho_{ij} &= \begin{cases} e^{\tau_{ij}} & \text{if } i \neq j \\ 1 & \text{if } i = j \end{cases} \\ \tau_{ii} &= 0\end{aligned}$$

- ▶  $\{\tau_{ij}\}$  행렬을 추정한 뒤  $\Gamma = \{\gamma_{ij}\}$  행렬로 변환

- 관측할 수 없는 discrete state를 추정han 후 이를 이용하여 다시 모형 파라미터를 추정하는 것을 반복

- ▶ E-step: discrete state  $C^{(T)}$  를 추정

$$\hat{u}(t) = \Pr(C_t = j | X^{(T)})$$

- ▶ M-step: 추정된  $u(t)$  가 맞다는 가정하에 MLE 방법으로 파라미터 추정

$$\arg \max_{\theta} L_T(\theta | X^{(T)}, C^{(T)})$$

## ❑ RHmm 패키지 사용

### ❑ HMMFit(obs, dis="NORMAL", nStates=2)

- ▶ obs: 관측값
- ▶ dis: 연속분포 모형 'NORMAL', 'DISCRETE', 'MIXTURE'
- ▶ nStates: 이산분포 state 수

## ❑ 출력

### ▶ HMM: HMM 파라미터

- initProb: 초기확률분포
- transMat: 전이확률행렬
- distribution: 연속확률분포 집합의 파라미터
  - mean: mean
  - var: variance



# HMM 추정 예

```
> (m <- HMMFit(simul$obs, "NORMAL", 3))

Call:
HMMFit(obs = simul$obs, dis = "NORMAL", nStates = 3)

Model:
3 states HMM with univariate gaussian distribution

Baum-Welch algorithm status:
Number of iterations : 85
Last relative variation of LLH function: 0.000001

Estimation:

Initial probabilities:
      Pi 1      Pi 2 Pi 3
1.277975e-87 3.06182e-22  1

Transition matrix:
      State 1      State 2      State 3
State 1 0.801038237 0.09657887 0.10238289
State 2 0.059976843 0.90135999 0.03866316
State 3 0.006631079 0.08464813 0.90872079

Conditionnal distribution parameters:

Distribution parameters:
      mean      var
State 1 -2.3373954 4.274560
State 2 -0.1285315 2.087011
State 3  0.9847118 1.086262

Log-likelihood: -4684.26
BIC criterium: 9478.05
AIC criterium: 9396.52
```

- 추정된 HMM 파라미터를 이용하여 마코프 체인의 discrete state를 추정하는 것을 디코딩(Decoding)이라 한다.
  - ▶ Local Decoding
    - 특정 시간  $t$ 에서 각 discrete state가 될 확률을 구하는 문제
  - ▶ Global Decoding (Path Finding)
    - 가장 Likelihood가 높은 마코프 체인의 discrete state 경로를 재현하는 문제
    - 비터비 (Viterbi) 알고리즘 사용

- RHmm 패키지 사용

- `forwardBackward(HMM, obs)`

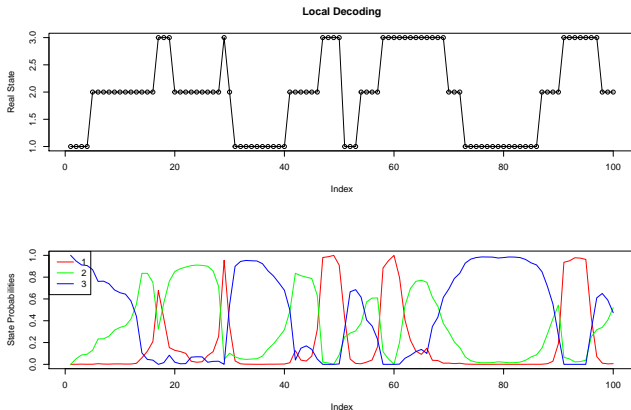
- ▶ HMM: `HMMFit` 명령으로 생성한 HMM 오브젝트
- ▶ obs: 관측값

- 출력

- ▶ Alpha:  $\alpha$
- ▶ Beta:  $\beta$
- ▶ LLH: Log-Likelihood

# Local Decoding 예

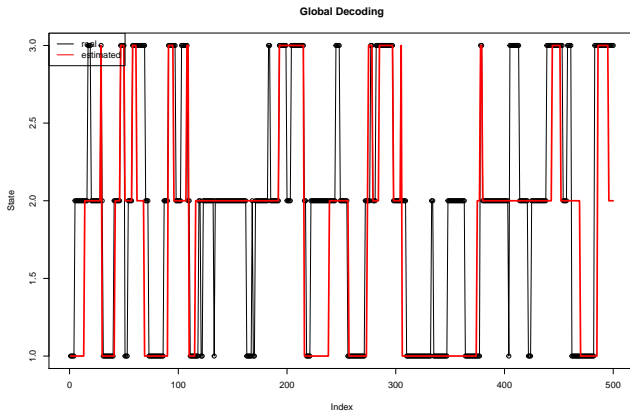
```
> fb <- forwardBackward(m, simul$obs)
> local <- exp(fb$Alpha+fb$Beta-fb$LLH)
> par(mfrow=c(2,1))
> plot(simul$states[1:100], type='o', main="Local Decoding", ylab="Real State")
> plot(local[1:100,1], type='l', col="red", ylab="State Probabilities")
> lines(local[1:100, 2], col="green")
> lines(local[1:100, 3], col="blue")
> legend("topleft", c("1", "2", "3"), col=c("red", "green", "blue"), lty=1)
```



- ❑ RHmm 패키지 사용
- ❑ `viterbi(HMM, obs)`
  - ▶ HMM: `HMMFit` 명령으로 생성한 HMM 오브젝트
  - ▶ obs: 관측값
- ❑ 출력
  - ▶ states: state path

# Global Decoding 예

```
> vitpath <- viterbi(m, simul$obs)
> states <- vitpath$states
> states[states==1] <- 0; states[states==3] <- 1; states[states==0] <- 3
> plot(simul$states[1:500], type='o', main="Global Decoding", ylab="State")
> lines(states[1:500], col="red", lwd=3, pch=4)
> legend("topleft", c("real", "estimated"), col=c("black", "red"), lty=1)
```



## 실제 주가에 HMM 응용

```
> library(quantmod)
> library(ITR)
> x <- getSymbols("KRX:005930", src="google", auto.assign=FALSE)
> p <- x$"KRX:005930.Close"
> r <- na.fill(coredata(ROC(p)),0)
> (sec.m <- HMMFit(r, "NORMAL", 2))
```

Call:

```
-----
HMMFit(obs = r, dis = "NORMAL", nStates = 2)
```

Model:

```
-----
2 states HMM with univariate gaussian distribution
```

Baum-Welch algorithm status:

```
-----
Number of iterations : 69
```

Last relative variation of LLH function: 0.000001

Estimation:

Initial probabilities:

Pi 1	Pi 2
9.911473e-35	1

Transition matrix:

	State 1	State 2
State 1	0.97810920	0.0218908
State 2	0.01141105	0.9885890

Conditionnal distribution parameters:

Distribution parameters:

	mean	var
State 1	-0.0002057263	0.0007788063
State 2	0.0007477859	0.0002484962


Log-likelihood: 4469.61

BIC criterium: -8886.81

AIC criterium: -8925.21

## 실제 주가에 HMM 응용

```
> sec.path <- viterbi(sec.m, r)
> plot(p, main="HMM Modeling for Samsung Electronics")
> points(p[sec.path$states == 1], pch=6, col="blue")
> points(p[sec.path$states == 2], pch=2, col="red")
```





## 실제 주가에 HMM 응용

```
> library(quantmod)
> library(ITR)
> x <- getSymbols("INDEXKRX:KOSPI200", src="google", auto.assign=FALSE)
> p <- x$"INDEXKRX:KOSPI200.Close"
> r <- na.fill(coredata(ROC(p)),0)
> (sec.m <- HMMFit(r, "NORMAL", 2))
```

Call:

----

HMMFit(obs = r, dis = "NORMAL", nStates = 2)

Model:

-----

2 states HMM with univariate gaussian distribution

Baum-Welch algorithm status:

-----

Number of iterations : 10

Last relative variation of LLH function: 0.000000

Estimation:

-----

Initial probabilities:

Pi 1	Pi 2
3.712691e-17	1

Transition matrix:

	State 1	State 2
State 1	0.97638991	0.02361009
State 2	0.00668076	0.99331924

Conditionnal distribution parameters:

Distribution parameters:

	mean	var
State 1	-0.001465504	0.0006846718
State 2	0.000645993	0.0001092940

Log-likelihood: 5188.82

BIC criterium: -10325.24

AIC criterium: -10363.64

## 실제 주가에 HMM 응용

```
> sec.path <- viterbi(sec.m, r)
> plot(p, main="HMM Modeling for KOSPI200")
> points(p[sec.path$states == 1], pch=6, col="blue")
> points(p[sec.path$states == 2], pch=2, col="red")
```

